

TUGAS– IoT CERDAS

Aplikasi IoT dan AI pada Precision Farming



Telkom
University

Nama : Rifqi Fadhila Shandi

NIM : 201012510024

1. Latar Belakang

Sektor pertanian dihadapkan pada tantangan global yang kompleks, termasuk pertumbuhan populasi, perubahan iklim, dan degradasi lahan. Metode pertanian konvensional yang mengandalkan pemantauan dan penanganan manual seringkali bersifat reaktif dan terlambat, menyebabkan kerugian hasil panen yang signifikan. Solusi tradisional ini terbukti tidak efisien untuk memenuhi tuntutan keberlanjutan dan produktivitas pangan modern.

Untuk mengatasi inefisiensi ini, Pertanian Presisi (*Precision Farming*) hadir sebagai solusi utama melalui integrasi Internet of Things (IoT) dan Kecerdasan Buatan (AI). Sistem ini menggunakan sensor untuk pengumpulan data *real-time* dan AI untuk pengambilan keputusan berbasis data, yang memungkinkan otomatisasi manajemen sumber daya dan pemantauan kesehatan tanaman. Berbagai penelitian, seperti yang ditunjukkan oleh Eze et al. (2025), menegaskan bahwa sinergi IoT dan AI ini sangat krusial dalam meningkatkan efisiensi produksi [1].

Secara spesifik, proyek ini berfokus pada Deteksi Penyakit Tanaman yang cepat dan akurat. Mengingat identifikasi manual terhambat oleh waktu dan ketersediaan tenaga ahli, proyek ini memanfaatkan teknologi visi komputer berbasis *Deep Learning*, khususnya Convolutional Neural Networks (CNN) [2]. Untuk memastikan efisiensi dan kemampuan *real-time* di lingkungan lahan yang mungkin memiliki konektivitas terbatas, proyek ini menggunakan arsitektur *Edge-Cloud* dan algoritma YOLO (You Only Look Once). YOLO, sebagai pengembangan CNN, memungkinkan deteksi dan lokalisasi penyakit dalam satu tahap pemrosesan, menghasilkan kinerja yang sangat efisien untuk diimplementasikan pada perangkat IoT. Dengan memanfaatkan *dataset* PlantVillage sebagai basis pelatihan, proyek ini bertujuan untuk merancang dan mengimplementasikan solusi IoT dan AI yang inovatif sebagai dasar untuk manajemen pertanian masa depan [3].

2. Tujuan Pembelajaran

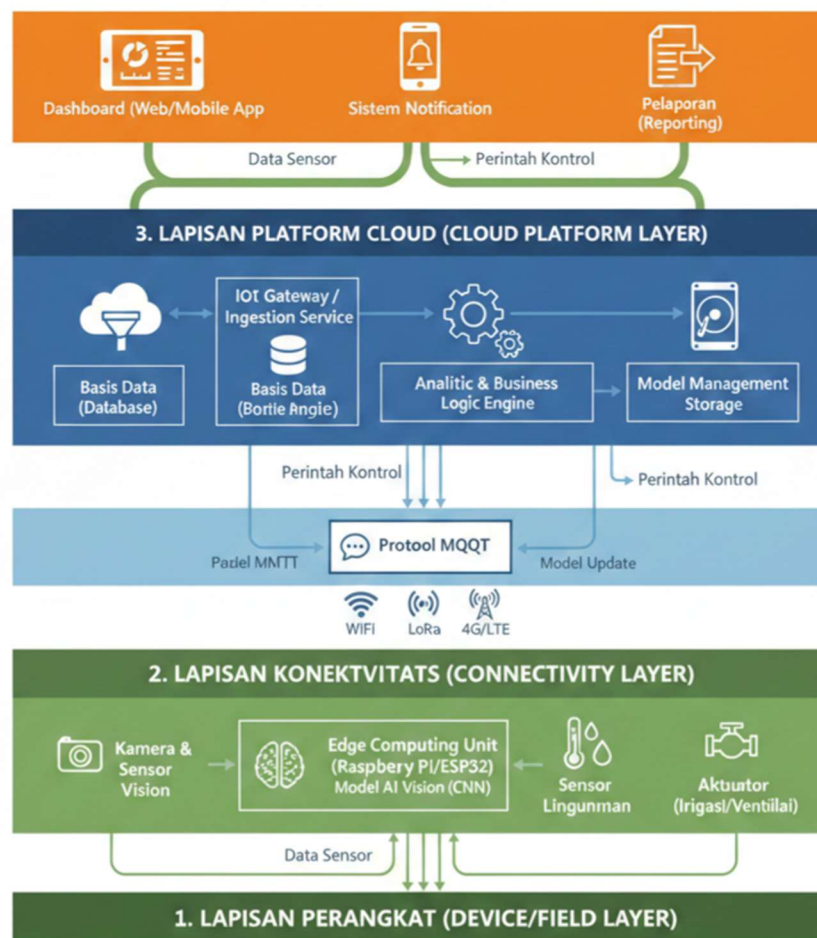
Berdasarkan latar belakang masalah yang telah diuraikan, tujuan pembelajaran yang ingin dicapai dalam tugas/proyek ini adalah agar mahasiswa mampu:

- a. Menjelaskan bagaimana Internet of Things (IoT) dan Kecerdasan Buatan (AI) membantu pertanian presisi meningkatkan produktivitas dan efisiensi operasional.
- b. Mendesain Arsitektur Sistem IoT Pertanian Berbasis Data Real-Time: Ini termasuk memilih sensor, aktuator, topologi jaringan, dan alur data yang menghubungkan perangkat lapangan (*edge*) ke sistem berbasis data secara *real-time*.

- c. Mengembangkan model AI/ML sederhana untuk pertanian. Mengimplementasikan dan melatih model machine learning, khususnya dengan metode visi komputer dengan YOLO, yang memiliki kemampuan untuk mengklasifikasikan kesehatan tanaman atau memproyeksikan kondisi pertanian dengan menggunakan dataset yang valid, yaitu PlantVillage.
- d. Mengevaluasi Tantangan, Etika, dan Dampak Sosial Mengevaluasi tantangan teknis yang terkait dengan penerapan teknologi serta konsekuensi etika dan sosial dari transformasi digital terhadap petani dan ekosistem pertanian secara keseluruhan.
- e. Mengkomunikasikan Hasil Analisis, Desain, dan Evaluasi Sistem: Menyusun hasil analisis ke dalam laporan akademik yang sistematis, logis, dan memenuhi standar penulisan ilmiah.

3. Rancangan Solusi Lengkap

3.1. Desain Arsitektur IoT



gambar 1\Diagram Blok Arsitektur Sistem IoT Precision Farming

a. Lapisan Perangkat Keras (Device Layer)

Lapisan ini adalah garis depan di lahan pertanian, terdiri dari sensor dan aktuator fisik.

- **Kamera & Sensor Vision:** Perangkat yang bertanggung jawab mengambil citra tanaman sebagai input utama untuk analisis kesehatan tanaman.
- **Sensor Lingkungan:** Perangkat yang mengukur parameter fisik lingkungan seperti Suhu Udara, Kelembaban Udara, dan Kelembaban Tanah. Data ini memberikan konteks penting bagi diagnosis AI.
- **Aktuator (Irigasi/Ventilasi):** Mekanisme fisik yang dapat dikontrol secara otomatis oleh sistem (misalnya, membuka katup air atau menyalakan kipas) untuk merespons kondisi tanaman atau lingkungan.
- **Edge Computing Unit (ECU):** Komputer mini (seperti Raspberry Pi atau Jetson Nano) yang bertindak sebagai otak lokal di lapangan. ECU ini menjalankan model AI (YOLO) untuk memproses citra secara langsung (*real-time*) dan mengelola komunikasi data dengan Cloud.

b. Lapisan Konektivitas (Connectivity Layer)

Infrastruktur komunikasi yang menghubungkan perangkat di lapangan dengan sistem di Cloud.

- **Protokol MQTT:** Protokol komunikasi standar IoT yang ringan dan efisien, digunakan untuk mengirimkan data (seperti hasil diagnosis YOLO dan data sensor) dari ECU ke Cloud dengan konsumsi bandwidth minimal.
- **Jaringan (WiFi / LoRa / 4G/LTE):** Media transmisi fisik yang digunakan. Pilihan jaringan (misalnya WiFi untuk kecepatan tinggi atau LoRa untuk jangkauan luas) disesuaikan dengan kondisi infrastruktur di lokasi pertanian.

c. Lapisan Platform Cloud (Cloud Platform Layer)

Pusat pemrosesan dan penyimpanan data sistem yang berlokasi di pusat data (cloud).

- **IoT Gateway / Broker:** Gerbang masuk yang aman bagi data yang dikirim dari ECU melalui MQTT.
- **Analitik & Logic Engine:** Layanan di Cloud yang memproses data yang masuk, menerapkan aturan bisnis (misalnya, memberikan peringatan jika penyakit terdeteksi di atas ambang batas tertentu), dan menghasilkan perintah kontrol untuk aktuator.
- **Database:** Sistem penyimpanan data terpusat yang menyimpan semua data historis, termasuk hasil diagnosis AI, pembacaan sensor, dan riwayat tindakan aktuator.

d. Lapisan Aplikasi (User/Application Layer)

Antarmuka pengguna untuk memantau dan mengendalikan sistem.

- **Dashboard (Web/Mobile App):** Aplikasi antarmuka visual yang memungkinkan petani untuk melihat status kesehatan tanaman secara *real-time*, menganalisis data historis sensor melalui grafik, dan mengontrol aktuator secara manual jika diperlukan.
- **Sistem Notifikasi:** Fitur yang secara otomatis mengirimkan peringatan kritis (melalui Email, SMS, atau notifikasi aplikasi) kepada petani ketika kondisi yang memerlukan perhatian segera terdeteksi oleh sistem.\

3.2. Model AI/ML

Bagian ini membahas tahapan teknis pengembangan model kecerdasan buatan, mulai dari persiapan data, pemilihan algoritma, hingga evaluasi kinerja model.

a. Pemilihan Dataset

Proyek ini menggunakan dataset publik PlantVillage, yang merupakan standar (benchmark) global dalam penelitian visi komputer untuk pertanian.

- **Sumber Data:** Dataset diunduh langsung dari repositori Kaggle (emmarex/plantdisease) menggunakan pustaka kagglehub.
- **Komposisi:** Dataset terdiri dari ribuan citra daun yang dikategorikan berdasarkan spesies tanaman dan jenis penyakit (misalnya: Tomato_Early_Blight, Tomato_Healthy, .).
- **Kualitas Data:** Citra dalam dataset ini diambil dalam kondisi lingkungan terkontrol dengan latar belakang seragam, yang ideal untuk pelatihan awal model klasifikasi guna mempelajari fitur visual penyakit secara spesifik.

b. Feature Engineering dan Pra-pemrosesan Data

Dalam pendekatan Deep Learning modern menggunakan YOLOv8, ekstraksi fitur dilakukan secara otomatis oleh lapisan konvolusi (convolutional layers). Oleh karena itu, rekayasa fitur difokuskan pada Pra-pemrosesan Data (Preprocessing) untuk memastikan data siap dipelajari oleh model:

- **Filtering Ekstensi:** Sistem memfilter dan hanya menerima file gambar dengan format valid (.jpg, .jpeg, .png) untuk mencegah kegagalan saat proses pembacaan data.
- **Pembagian Data (Data Splitting):** Dataset dibagi menggunakan metode stratified sampling dengan rasio 80:20:
 - 80% Data Latih (Training Set): Digunakan model untuk mempelajari pola fitur penyakit.

- 20% Data Validasi (Validation Set): Digunakan untuk mengevaluasi kinerja model pada data yang belum pernah dilihat selama proses pelatihan.
 - **Resizing (Penyeragaman Dimensi):** Sesuai konfigurasi *imgsz* = 224 pada kode pelatihan, seluruh citra masukan diubah ukurannya menjadi 224 x 224 piksel. Ukuran ini adalah standar optimal untuk model klasifikasi yang menyeimbangkan detail visual dengan efisiensi komputasi.
 - **Normalisasi:** Secara internal, YOLOv8 menormalisasi nilai piksel (0-255) menjadi rentang (0-1) untuk mempercepat konvergensi gradien.
- c. Algoritma yang Digunakan
- Algoritma yang diterapkan adalah YOLOv8 (*You Only Look Once* version 8) dalam mode Klasifikasi.
- **Varian Model: yolov8s-cls.pt (Small Version).**
 - **Analisis Pemilihan:** Varian 'Small' dipilih karena memiliki jumlah parameter yang sedikit lebih besar daripada varian 'Nano'. Hal ini memberikan kapasitas yang lebih baik untuk mengenali pola penyakit yang kompleks dan mirip satu sama lain, namun tetap cukup ringan untuk dijalankan pada perangkat dengan sumber daya terbatas.
 - **Arsitektur:** Menggunakan *backbone* CSP (Cross Stage Partial) yang efisien untuk mengekstrak fitur, diikuti oleh *classification head* yang memprediksi probabilitas kelas penyakit.
- d. Evaluasi Performa Model
- Evaluasi kinerja model dilakukan menggunakan dataset validasi yang terdiri dari **4.134 sampel citra**. Berdasarkan hasil pengujian, model YOLOv8-Classification yang dikembangkan menunjukkan performa yang sangat tinggi dan konsisten di berbagai kelas penyakit.

Berikut adalah rincian metrik evaluasi yang diperoleh:

1. **Akurasi Keseluruhan (Overall Accuracy)** Model berhasil mencapai tingkat akurasi sebesar **99.73%**. Angka ini menunjukkan bahwa model mampu mengklasifikasikan hampir seluruh citra uji dengan benar, membuktikan bahwa arsitektur model telah belajar dengan sangat baik dalam membedakan fitur visual antar penyakit tanaman.
2. **Laporan Klasifikasi Per Kelas (Classification Report)** Berikut adalah tabel ringkasan performa model untuk setiap kelas penyakit berdasarkan metrik *Precision*, *Recall*, dan *F1-Score*:

```
Memuat model terbaik dari: /content/PlantVillagev1.pt
Menjalankan prediksi pada dataset validasi...

=====
HASIL EVALUASI LENGKAP
=====
Overall Accuracy: 0.9973
-----
Laporan Klasifikasi Per Kelas:
```

	precision	recall	f1-score	support
Pepper_bell_Bacterial_spot	1.0000	0.9850	0.9924	200
Pepper_bell_healthy	0.9933	0.9966	0.9949	296
Potato_Early_blight	1.0000	1.0000	1.0000	200
Potato_Late_blight	1.0000	0.9950	0.9975	200
Potato_healthy	1.0000	1.0000	1.0000	31
Tomato_Bacterial_spot	1.0000	1.0000	1.0000	426
Tomato_Early_blight	1.0000	0.9950	0.9975	200
Tomato_Late_blight	0.9948	1.0000	0.9974	382
Tomato_Leaf_Mold	1.0000	1.0000	1.0000	191
Tomato_Septoria_leaf_spot	0.9944	0.9972	0.9958	355
Tomato_Spider_mites_Two_spotted_spider_mite	0.9940	0.9940	0.9940	336
Tomato_Target_Spot	0.9929	0.9929	0.9929	281
Tomato_YellowLeaf_Curl_Virus	1.0000	1.0000	1.0000	642
Tomato_Tomato_mosaic_virus	0.9868	1.0000	0.9934	75
Tomato_healthy	1.0000	1.0000	1.0000	319
accuracy			0.9973	4134
macro avg	0.9971	0.9970	0.9971	4134
weighted avg	0.9973	0.9973	0.9973	4134

3. Analisis Hasil

- **Performa Sempurna:** Sejumlah kelas mencapai skor F1 sempurna (1.00), termasuk *Potato Early Blight*, *Potato Healthy*, *Tomato Bacterial Spot*, *Tomato Leaf Mold*, *Tomato YellowLeaf Curl Virus*, dan *Tomato Healthy*. Hal ini mengindikasikan ciri visual penyakit-penyakit tersebut sangat khas dan dapat diekstraksi dengan sempurna oleh model.
- **Keseimbangan Precision dan Recall:** Nilai *Precision* dan *Recall* sangat seimbang di hampir semua kelas. Nilai *Recall* terendah tercatat pada *Pepper Bell Bacterial Spot* (98.50%), yang berarti model melewatkan sekitar 1.5% kasus positif pada penyakit ini, namun angka tersebut masih dalam kategori sangat baik untuk implementasi lapangan.
- **Ketahanan terhadap Ketidakseimbangan Data:** Meskipun terdapat ketimpangan jumlah data (*support*) yang signifikan—misalnya *Potato Healthy* hanya memiliki 31 sampel dibandingkan *Tomato YellowLeaf Curl Virus* yang memiliki 642 sampel—model tetap mampu memberikan prediksi yang akurat tanpa bias terhadap kelas mayoritas.
- **Kesimpulan:** Dengan *Weighted Average F1-Score* sebesar **99.73%**, model ini dinyatakan sangat layak (*deployment-ready*) untuk diintegrasikan ke

dalam sistem IoT *Precision Farming* guna mendeteksi penyakit tanaman secara *real-time*.

4. Analisis Dampak, Risiko, dan Etika (10%)

Penerapan teknologi *Internet of Things* (IoT) dan Kecerdasan Buatan (AI) dalam sektor pertanian (*Precision Farming*) membawa perubahan paradigma yang signifikan. Selain manfaat teknis, implementasi sistem deteksi penyakit tanaman berbasis YOLOv8 ini juga perlu dikaji dari aspek risiko, dampak sosial-ekonomi, serta pertimbangan etika untuk memastikan keberlanjutan solusi.

4.1 Risiko Implementasi Teknologi

Peralihan dari pertanian konvensional ke pertanian cerdas berbasis data menghadirkan kerentanan baru yang harus dimitigasi:

1. Risiko Keamanan Siber (*Cybersecurity Risks*)

- **Kerentanan Perangkat Edge:** Perangkat IoT seperti Raspberry Pi dan sensor yang terpasang di lahan terbuka sering kali memiliki keamanan fisik dan *firmware* yang lemah. Risiko pembajakan perangkat (*device hijacking*) untuk serangan *botnet* atau manipulasi data sensor (*data spoofing*) dapat terjadi.
- **Insecuritas Protokol:** Pengiriman data melalui protokol MQTT tanpa enkripsi (TLS/SSL) berisiko disadap (*eavesdropping*). Jika penyerang memanipulasi data status penyakit, sistem bisa memberikan rekomendasi yang salah (misalnya: mematikan irigasi saat tanaman butuh air), yang berpotensi merusak panen.

2. Kegagalan dan Eror AI (*AI Reliability*)

- **False Positives (Salah Deteksi Sakit):** Jika model memprediksi tanaman sehat sebagai sakit (Presisi rendah), petani akan membuang biaya untuk pestisida yang tidak perlu, yang juga mencemari lingkungan.
- **False Negatives (Gagal Deteksi):** Jika model gagal mendeteksi tanaman yang benar-benar sakit (Recall rendah), wabah penyakit dapat menyebar luas sebelum petani menyadarinya, menyebabkan gagal panen total.
- **Drift Model:** Seiring berjalannya waktu, karakteristik penyakit atau varietas tanaman bisa berubah. Model yang tidak diperbarui (*re-training*) akan mengalami penurunan akurasi.

3. Bias Data (*Data Bias*)

- **Representasi Lingkungan:** Model dilatih menggunakan dataset **PlantVillage** yang diambil dalam kondisi laboratorium dengan latar belakang seragam. Implementasi di lapangan dengan latar belakang tanah, gulma, dan pencahayaan dinamis dapat memicu bias prediksi, di

mana model gagal mengenali penyakit pada kondisi visual yang belum pernah dipelajari sebelumnya (*Out-of-Distribution Data*).

4.2 Dampak Sosial-Ekonomi bagi Petani

Transformasi digital di sektor pertanian menciptakan dampak ganda yang mempengaruhi struktur sosial dan ekonomi petani:

1. Dampak Positif (Peningkatan Ekonomi)

- **Efisiensi Biaya Produksi:** Dengan deteksi dini dan presisi, penggunaan pestisida dan pupuk dapat dilakukan secara terukur (hanya pada tanaman yang sakit). Ini mengurangi biaya operasional secara signifikan.
- **Peningkatan Kuantitas & Kualitas Panen:** Intervensi cepat terhadap penyakit mencegah kerusakan tanaman yang meluas, sehingga tonase hasil panen meningkat dan kualitas produk lebih terjaga (minim residu kimia).

2. Tantangan Sosial (Kesenjangan Digital)

- **Digital Divide:** Teknologi ini membutuhkan literasi digital dan akses infrastruktur (internet stabil, listrik) yang mungkin belum merata di pedesaan. Petani skala kecil dengan modal terbatas berisiko tertinggal dibandingkan korporasi pertanian besar yang mampu mengadopsi teknologi ini.
- **Pergeseran Keterampilan:** Peran petani bergeser dari tenaga kerja manual intensif menjadi manajer berbasis data. Hal ini menuntut pelatihan ulang (*upskilling*), yang jika tidak difasilitasi, dapat menimbulkan resistensi adopsi teknologi.

4.3 Pertimbangan Etika dan Keberlanjutan

Pengembangan sistem cerdas harus berlandaskan pada prinsip-prinsip etika dan keberlanjutan lingkungan jangka panjang:

1. Etika Kecerdasan Buatan (*AI Ethics*)

- **Transparansi dan Penjelasan (*Explainability*):** Sistem AI tidak boleh menjadi "kotak hitam" (*black box*). Petani berhak tahu mengapa sistem merekomendasikan tindakan tertentu (misalnya: "Sistem mendeteksi *Early Blight* dengan keyakinan 99%").
- **Kepemilikan Data (*Data Ownership*):** Data citra dan kondisi lahan yang dikumpulkan adalah milik petani. Pengembang sistem harus memastikan data tersebut tidak disalahgunakan atau dijual ke pihak ketiga (misalnya perusahaan asuransi atau pestisida) tanpa persetujuan eksplisit petani.

2. Keberlanjutan Lingkungan (*Sustainability*)

- **Pertanian Ramah Lingkungan:** Sistem ini mendukung konsep *Sustainable Agriculture* dengan mengurangi penggunaan bahan kimia berlebih (*agrochemicals*) melalui penyemprotan presisi. Ini menjaga kesehatan tanah dan air tanah dari pencemaran.
- **Isu Limbah Elektronik (E-Waste):** Penggunaan perangkat IoT dalam jumlah besar berpotensi menjadi limbah elektronik di masa depan. Perancangan perangkat keras harus mempertimbangkan masa pakai yang panjang dan kemudahan daur ulang komponen sensor maupun baterai.

5. Kesimpulan Akhir (Penutup Laporan)

Proyek ini telah berhasil mendemonstrasikan perancangan arsitektur sistem IoT dan pengembangan model AI (YOLOv8) untuk deteksi penyakit tanaman dengan akurasi pengujian mencapai **99.73%**. Integrasi antara kemampuan deteksi cerdas dan konektivitas IoT menawarkan solusi konkret untuk tantangan efisiensi dalam pertanian modern.

Meskipun demikian, keberhasilan implementasi di dunia nyata tidak hanya bergantung pada akurasi model, tetapi juga pada kesiapan infrastruktur, keamanan sistem, dan adopsi sosial oleh petani. Pengembangan selanjutnya disarankan untuk fokus pada pengumpulan dataset lapangan (*in-the-wild*) untuk mengurangi bias, serta penguatan keamanan siber pada perangkat *Edge*. Dengan pendekatan yang holistik, teknologi ini memiliki potensi besar untuk mewujudkan ketahanan pangan yang berkelanjutan.

Daftar Pustaka

1. Referensi Utama (Dikutip di Latar Belakang)

- Eze, V. H. U., et al. (2025). "Integration of Artificial Intelligence (AI) and Internet of Things (IoT) in Smart Agriculture: A Review." *Discover Agriculture*, 3(1), 1-15. (Jurnal terbaru yang Anda kutip di Bab 1 tentang integrasi AI-IoT).

2. Referensi Dataset (PlantVillage)

- Hughes, D. P., & Salathé, M. (2015). "An open access repository of images on plant health to enable the development of mobile disease diagnostics." *arXiv preprint arXiv:1511.08060*. (Ini adalah sitasi resmi untuk pembuat dataset PlantVillage).
- Mohanty, S. P., Hughes, D. P., & Salathé, M. (2016). "Using Deep Learning for Image-Based Plant Disease Detection." *Frontiers in Plant Science*, 7, 1419. (Paper seminal yang membuktikan penggunaan Deep Learning pada dataset PlantVillage).

3. Referensi Algoritma (YOLO & Deep Learning)

- Jocher, G., Chaurasia, A., & Qiu, J. (2023). *Ultralytics YOLOv8*. Ultralytics. Tersedia di: <https://github.com/ultralytics/ultralytics>. (Sitasi resmi untuk *software/framework* YOLOv8 yang Anda gunakan).
- Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). "You Only Look Once: Unified, Real-Time Object Detection." *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 779-788. (Dasar teori algoritma YOLO).
- Terven, J., & Cordova-Esparza, D. (2023). "A Comprehensive Review of YOLO Architectures in Computer Vision: From YOLOv1 to YOLOv8 and YOLO-NAS." *Machine Learning and Knowledge Extraction*, 5(4), 1680-1716. (Referensi bagus untuk menjelaskan evolusi kenapa Anda memilih YOLOv8).

4. Referensi Sistem IoT & Edge Computing

- Friha, O., et al. (2021). "Internet of Things for the Future of Smart Agriculture: A Comprehensive Survey of Emerging Technologies." *IEEE/CAA Journal of Automatica Sinica*, 8(4), 718-752. (Referensi untuk arsitektur IoT dan sensor).
- Sinha, B. B., & Dhanalakshmi, R. (2022). "Recent advancements and challenges of Internet of Things in smart agriculture: A survey." *Future Generation Computer Systems*, 126, 169-184. (Mendukung pembahasan tentang tantangan konektivitas dan *Edge Computing*).